# DOCUMENT AGENT EVALUATION REPORT

## 실제 공개 문서 양식 8 종 재측정 결과

**평가일:** 2026-08-13 (KST)

**코드 기준:** origin/main 9298e1feb3d1

**모델:** gemini-3.6-flash

**재측정 정책:** 최초 결과 없음 2 건만 각 1 회, 자동 재시도 없음, 호출 시작 간격 40 초

**결론 | 8 개 고유 양식 중 7 개에서 유효한 구조화 결과를 확보했다. 유효 결과의 필드 값은 98/98 로 모두 정확했다. 문서 유형까지 포함한 완전 일치는 6/7 이다. GSA 3025 는 두 번 모두 응답 스키마 검증에 실패해 정확도 판정에서 제외했다.**

## 핵심 지표

| 지표 | 결과 | 비율 | 분모/해석 |
|---|---|---|---|
| 유효 구조화 결과 | 7 / 8 | 87.5% | 최종 고유 양식 기준 |
| 완전 일치 | 6 / 7 | 85.7% | 유효 결과 기준 |
| 전체 필드 값 | 98 / 98 | 100.0% | 값+예상 null |
| 값이 있는 필드 | 74 / 74 | 100.0% | 문자열 정확 일치 |
| 예상 null 필드 | 24 / 24 | 100.0% | null 판정 |
| 문서 유형 | 6 / 7 | 85.7% | 사전 단일 라벨 기준 |
| 총 API 호출 | 10 | - | 최초 8 회 + 재측정 2 회 |

주의: 100% 필드 정확도는 유효한 구조화 응답 7 건에 한정된 조건부 값이다. 응답 생성 실패 1 건을 포함한 전체 서비스 성공률과 구분해야 한다.

# 1. 평가 목적과 범위

**목적:** 회사마다 다른 문서 양식에서도 Document Agent 가 지원하는 항목 식별과 값 추출을 얼마나 정확히 수행하는지 측정했다.

**입력:** Adobe 및 미국 GSA 의 공개 원본 양식 8 종에 사전에 고정한 합성 평가값을 기입했다. 실제 기업의 발행 거래문서나 개인정보는 사용하지 않았다.

**판정:** 모델 호출 전에 작성한 expected.json 과 문서 유형, 14 개 구조화 필드, 누락 필드 목록을 정확 일치로 비교했다.

**포함:** 문서 유형 분류, 보이는 값 추출, 예상 null 과 누락 항목 식별.

**제외:** 문서 내용의 진위·조작 여부 판정. 또한 이번 8 개 케이스는 각 1 문서이므로 문서 간 값 불일치 검출 정확도는 측정하지 않았다.

# 2. 실행 조건

| 항목 | 설정 |
|---|---|
| 코드 | origin/main (9298e1feb3d1) |
| 모델 | gemini-3.6-flash |
| 첫 실행 | 8 개 양식 각 1 회 |
| 재측정 | 결과 없음 2 건만 각 1 회 |
| 재시도 | 자동 재시도 없음 (GEMINI_MAX_ATTEMPTS=1) |
| 호출 간격 | 시작 시각 기준 최소 40 초 |
| 타임아웃 | 건당 120 초 |
| fixture 검증 | 8 문서, 10 페이지, 사전 검증 통과 |

## 3. 최초 측정과 재측정

| 구분 | 호출/양식 | 유효 결과 | 완전 일치 | 비고 |
|---|---|---|---|---|
| 최초 | 8 | 6 | 5 | OF348: HTTP 503 / GSA3025: 스키마 검증 실패 |
| 재측정 | 2 | 1 | 1 | OF348: 정확 일치 / GSA3025: 동일 검증 실패 |
| 최종 고유 양식 | 8 | 7 | 6 | GSA3025 1 건은 측정 불가 |

## 4. 양식별 최종 결과

| 공개 원본 양식 | 최종 상태 | 상세 |
|---|---|---|
| Adobe Proforma Invoice | **정확 일치** | 유형·14 필드·누락 목록 일치 |
| GSA 3708 Invoice | **정확 일치** | 유형·14 필드·누락 목록 일치 |
| GSA 300 Purchase Order | **정확 일치** | 유형·14 필드·누락 목록 일치 |
| OF 348 Order Schedule | **회복: 정확 일치** | 유형·14 필드·누락 목록 일치 |
| SF 26 Award/Contract | **정확 일치** | 유형·14 필드·누락 목록 일치 |
| SF 1449 Solicitation/Contract/Order | **유형 라벨 불일치** | 필드 14/14 일치; CONTRACT 기대, PURCHASE_ORDER 출력 |
| GSA 3025 Receiving Report | **측정 불가: AI_RESPONSE_INVALID** | 최초·재측정 모두 구조 검증 실패 |
| GSA 1678 Shipment Report | **정확 일치** | 유형·14 필드·누락 목록 일치 |

## 5. 판정 해석

**OF348:** 최초 HTTP 503 은 정확도 오답이 아니며 재측정에서 유형과 14 개 필드가 모두 정확했다. 최종 고유 양식 지표에는 재측정 결과를 사용했다.

**GSA3025:** 두 호출 모두 AI_RESPONSE_INVALID 로 종료돼 추출값 자체가 없다. 따라서 필드 정확도 분모에 넣지 않고 측정 불가로 남겼다. 다만 서비스 관점에서는 반복된 유효 응답 실패다.

**SF1449:** 14 개 필드와 누락 목록은 모두 정확했으나 사전 라벨 CONTRACT 대신 PURCHASE_ORDER 로 분류했다. 공식 양식명이 Solicitation/Contract/Order 인 다목적 양식이므로 엄격 점수는 오답으로 유지하되 명백한 의미 오류로 단정하지 않는다.

## 6. 결론과 한계

**지원 작업 기준 결론 | 유효 응답 7 건에서 보이는 값과 예상 null 은 98/98 로 정확했다. 단일 문서 유형 라벨까지 포함한 완전 일치는 6/7 였다. 가장 분명한 개선 과제는 GSA3025 에서 반복된 구조화 응답 실패다.**

**일반화 한계:** 표본은 공개 양식 8 종, 각 1 개 값 세트이며 반복 표본이 충분하지 않다. 따라서 전체 기업 문서에 대한 통계적 정확도로 해석할 수 없다.

**진위 판정 한계:** 문서에 적힌 값이 실제 거래 사실인지, 조작됐는지, 발행 주체가 진짜인지 판별하는 시험은 아니다. 이 부분은 외부 원장·서명·발행처 확인 또는 사람 검토가 필요하다.

**불일치 검출 한계:** 이번 세트는 양식 적응력을 보기 위한 단일 문서 케이스다. 문서 간 값 불일치 검출 정확도는 별도의 다문서 시나리오 결과로 보고해야 한다.

# 7. 공개 원본 출처

| No. | 양식 | 원문 URL |
|---|---|---|
| 1 | Adobe Proforma Invoice Template | https://www.adobe.com/dc-shared/assets/pdf/acrobat/business/resources/proforma-invoice-template.pdf |
| 2 | GSA Form 3708 Invoice | https://www.gsa.gov/cdnstatic/GSA3708-14.pdf |
| 3 | GSA Form 300 Order for Supplies and Services | https://www.gsa.gov/system/files/GSA300-21.pdf |
| 4 | Optional Form 348 Order Schedule Continuation | https://www.gsa.gov/cdnstatic/OF348-06.pdf |
| 5 | Standard Form 26 Award Contract | https://www.gsa.gov/system/files/SF26-22.pdf |
| 6 | Standard Form 1449 Solicitation Contract Order | https://www.gsa.gov/system/files/SF1449-21.pdf |
| 7 | GSA Form 3025 Receiving Report | https://www.gsa.gov/system/files/GSA3025-05.pdf |
| 8 | GSA Form 1678 Status Report of Orders and Shipments | https://www.gsa.gov/system/files/2025-04/GSA1678-15e.pdf |

원본 및 기입본 SHA-256 은 source-manifest.json 에 보존돼 있다. 모든 기입 값은 공개 원본 레이아웃에 넣은 합성 평가값이다.