DOCUMENT AGENT

종합 성능평가 보고서

같은 양식 · 다른 양식 · 실제 공개 양식

메모 항목	내용
평가일	2026-08-12~13 (KST)
기준 코드	origin/main 9298e1feb3d1
모델	gemini-3.6-flash
판정 원칙	정답을 모델 호출 전에 고정하고, 유효 구조화 응답만 의미 정확도 분모에 포함
보고 범위	문서 종류, 14 개 구조화 필드, 누락 필드, 문서 간 불일치, reviewRequired

핵심 결론 | 유효 결과 25 건 중 엄격 완전 일치 24 건(96.0%), 필드 값 1,106/1,106(100%), 문서 간 불일치 16/16 검출. 단, 전체 설계 35 건 중 25 건만 유효 결과를 받아 커버리지는 71.4%이며 반복성은 아직 측정하지 않았습니다.

1. 평가 질문과 판정 원칙

질문 Document Agent 가 지원하는 추출·문서 종류 식별·문서 간 값 불일치 판정을 얼마나 정확히 수행하는가?

정확도 구조화 응답이 반환된 고유 사례에서 고정된 expected.json 과 결과를 비교합니다.

가용성 HTTP 429/503, AI_RESPONSE_INVALID 처럼 결과가 없는 호출은 의미 오류로 섞지 않고 별도 집계합니다.

한계 문서 내부 정보가 진짜인지, 위조·조작됐는지는 이 시험과 현재 Agent 의 판정 범위가 아닙니다.

2. 전체 결과

지표	실측	비율	해석
고유 사례 커버리지	25 / 35	71.4%	10 건은 결과 미반환
엄격 완전 일치	24 / 25	96.0%	유효 결과 기준
문서 전체 일치	78 / 79	98.7%	SF 1449 유형 1 건 불일치
문서 종류	78 / 79	98.7%	엄격 단일 라벨
14 개 필드 셀	1106 / 1106	100.0%	값 및 null
값이 있는 필드	826 / 826	100.0%	정규화 비교
예상 null 필드	280 / 280	100.0%	누락 처리

96.0%는 전체 35 건이 아니라 유효 응답 25 건의 조건부 정확도입니다. 따라서 제품 성능 설명에는 71.4% 커버리지와 함께 제시해야 합니다.

3. 시험 1 — 같은 양식

기존 4 문서 템플릿을 고정하고 정상·표기 변형·단일 불일치·복합 불일치만 바꿔 추출과 비교 로직의 기본 정확도를 측정했습니다.

항목	결과	판정
설계 / 측정	19 / 11 세트	**8 세트 HTTP 429 미측정**
문서	44 / 44	**완전 일치**
필드 셀	616 / 616	**100%**
값 / null	451 / 451 · 165 / 165	모두 일치
불일치	TP 11 · FP 0 · FN 0	**정밀도·재현율·F1 100%**
reviewRequired	11 / 11	**100%**
정상 세트 오탐	0 / 3	오탐 없음

해석 고정 양식 안에서는 필드 추출과 문서 간 값 비교가 측정된 모든 사례에서 정확했습니다.

제한 8 세트는 무료 API 429 로 구조화 결과를 받지 못했고, 측정된 각 사례도 성공 실행 1 회뿐입니다.

4. 시험 2 — 다른 회사의 신규 양식

양식을 학습·등록하지 않은 조건을 모사해 서로 다른 레이아웃 8 세트, 총 32 PDF 를 블라인드 평가했습니다.

ID	레이아웃	기대 불일치	최종 결과
u01	ERP 그리드	정상	**완전 일치**
u02	영문 수출 상업문서	정상	**완전 일치**
u03	이중언어 사이드바	정상	**완전 일치**
u04	2 페이지 법률형	totalAmount	**완전 일치**
u05	미니멀 카드형	supplierName	**완전 일치**
u06	레거시 단색	quantity	**완전 일치**
u07	가로형 조달	currency, totalAmount	**완전 일치**
u08	래스터 전용 스캔	PO 번호, itemName	**HTTP 503 · 미측정**

요약 지표	결과
고유 양식 결과 확보	7 / 8 (87.5%)
유효 세트 완전 일치	7 / 7
문서 / 필드	28 / 28 · 392 / 392
불일치	5 / 5, FP 0, FN 0
호출 가용성	7 / 11 (63.6%)

해석 새 레이아웃 7 종에서도 유효 결과가 나온 경우 추출·누락·불일치 판정이 모두 정확했습니다.

제한 텍스트 레이어가 없는 u08 은 두 차례 모두 HTTP 503 이라 스캔 정확도를 확정할 수 없습니다. u03 기록의 시계 이상으로 지연시간 통계도 제외했습니다.

5. 시험 3 — 실제 공개 양식

Adobe 와 미국 GSA 가 공개 배포한 양식 8 종의 레이아웃에 알려진 합성 값을 채워 단일 문서 추출과 유형 식별을 측정했습니다. 실제 거래 원본은 아닙니다.

공개 양식	엄격 기대 유형	최종 결과
Adobe Proforma	INVOICE	**완전 일치**
GSA 3708	INVOICE	**완전 일치**
GSA 300	PURCHASE_ORDER	**완전 일치**
OF 348	PURCHASE_ORDER	**재측정 후 완전 일치**
SF 26	CONTRACT	**완전 일치**
SF 1449	CONTRACT	**필드 일치 · 유형 불일치**
GSA 3025	DELIVERY_EVIDENCE	**AI_RESPONSE_INVALID · 미측정**
GSA 1678	DELIVERY_EVIDENCE	**완전 일치**

요약 지표	결과	해석
고유 양식 결과 확보	7 / 8	**1 건 미측정**
엄격 완전 일치	6 / 7	85.7%
필드 값	98 / 98	**100%**
문서 종류	6 / 7	85.7%
호출 가용성	7 / 10	70.0%

SF 1449 14 개 필드는 모두 정확했지만, 복수 용도의 Solicitation/Contract/Order 양식을 Agent 가 PURCHASE_ORDER 로 분류해 엄격 CONTRACT 정답과 달랐습니다.

GSA 3025 두 번 모두 구조화 응답 검증 실패라 의미 정확도 분모에서 제외했습니다. 이는 단순 API 503 과 다른 출력 안정성 문제입니다.

불일치 판정 이 시험은 사례당 문서 1 개이므로 문서 간 값 불일치 성능을 측정하지 않습니다.

6. Document Agent 성능 평가

잘하는 작업 유효 응답이 반환되면 정해진 14 개 필드의 값·null 을 매우 정확히 추출했고, 다문서 시험 18 건에서 기대 불일치 16 개를 모두 찾으면서 오탐을 만들지 않았습니다.

확인된 오류 실제 공개 다목적 양식 1 건에서 엄격 문서 유형 라벨이 달랐습니다. 필드 값 오류는 측정된 1,106 개 결정에서 없었습니다.

운영 리스크 무료 API 의 429/503 과 구조화 응답 검증 실패 때문에 설계 사례 35 건 중 10 건은 정확도를 측정하지 못했습니다.

아직 말할 수 없는 것 반복 실행 안정성, 모든 회사 양식에 대한 일반화, 스캔 PDF 정확도, 위조·조작 정보 판정은 이번 값으로 확정할 수 없습니다.

문서 간 불일치 지표	실측	비율
적용된 유효 세트	18	—
기대 불일치 검출	16 / 16	**100%**
오탐 / 누락	0 / 0	0 / 0
reviewRequired	18 / 18	**100%**

7. 짧은 개선 방향

- 반복성: 대표 사례별 10 회 반복 측정 후 평균과 최악값을 함께 보고합니다.
- 구조화 출력: GSA 3025 의 검증 실패 원문 형태를 보존하고, 오류를 숨기지 않는 스키마 검증·제한적 복구 경로를 설계합니다.
- 유형 정책: SF 1449 같은 다목적 양식은 단일 정답 규칙 또는 다중 라벨 정책을 먼저 고정합니다.
- 미측정 해소: 같은 양식 8 건과 래스터 스캔 u08 을 동일 fixture·고정 한도에서 재측정합니다.

8. 결론

현재 근거로 Document Agent 의 강점은 '보이는 값을 구조화하고 여러 문서의 값을 비교하는 작업'입니다. 유효 결과 기준 필드 정확도와 불일치 판정은 모두 100%였지만, 유형 분류 1 건과 결과 미반환 10 건이 있어 전체 시스템을 100%라고 표현하면 안 됩니다.

위조·조작된 정보의 진위 판단은 사람이 하거나 외부 원천 검증을 결합해야 합니다. 이 한계는 무료 API 사용 때문만이 아니라 현재 평가 목표와 Agent 기능 범위 자체의 경계입니다.

부록 A. 근거 파일

시험	근거 경로
같은 양식	test/document-agent/same-format-v1/fixtures · results/merged-summary.json
다른 양식	test/document-agent/different-format-v1/fixtures · results/summary.json
실제 공개 양식	test/document-agent/real-public-v1/fixtures · results · reports
종합 기계 판독값	test/document-agent/reports/document-agent-performance-evaluation-2026-08-13-summary.json